

Roteiro Consolidado — Apresentação TCC V-AGMD

Abrir / Slide de Título

Boa tarde. Este é o meu projeto final de graduação, cujo título é “**Modelagem Híbrida com Regularização Física e Seleção Parcimoniosa de Modelos para Predição de Desempenho em Destilação por Membranas**”.

Sumário

Este é o sumário do TCC: vamos começar com a **introdução**, depois **revisão bibliográfica**, **fundamentação teórica**, **metodologia proposta**, seguindo para **resultados**, **conclusões** e **referências**.

1. A Crise Global da Água

A crise global da água é tanto de quantidade quanto de qualidade. **4 bilhões** de pessoas enfrentam escassez severa de água, sendo que **2,2 bilhões** não têm acesso a água potável segura. A demanda global deve superar a oferta em **40% até 2030**.

2. O Problema no Brasil

No Brasil, 2026 foi um ano desafiador, com chuvas abaixo da média. O **Sistema Cantareira** operou a aproximadamente **30%** da sua capacidade. No Nordeste, um cenário de **4 meses de chuva para 8 meses de seca extrema**.

A dessalinização pode reduzir o custo da água em até **10 vezes** — de R\$ 2,63 a R\$ 4,21/m³ (CNI). A maior planta do Brasil (ES) atende **80 mil pessoas**. Com **8.500 km de costa**, o potencial de expansão para essa tecnologia é enorme.

3. Dessalinização — Contexto Global

A dessalinização já é uma realidade consolidada globalmente. Mais de **150 países** usam a tecnologia. Na Arábia Saudita, responde por **86%** do abastecimento; em Israel, **80%**.

4. V-AGMD no Contexto da Dessalinização

A dessalinização divide-se em duas grandes famílias: processos **térmicos** (destilação convencional) e processos de **membrana** (osmose inversa, MD). A **Destilação por Membrana (MD)** é um

processo híbrido termo-membrana: uma membrana hidrofóbica separa o vapor d'água da salmoura aquecida.

A configuração **V-AGMD** combina um **espaço de ar** (que funciona como isolante térmico) com **vácuo parcial** (que reduz a resistência ao transporte de vapor). O ar impede a troca de calor entre os lados quente e frio, tornando o sistema energeticamente eficiente. O vácuo compensa o impedimento ao transporte de massa causado pelo air gap.

5. Ilha de Policogeração Sustentável

Este trabalho está inserido no projeto **CT2 — Ilha de Policogeração Sustentável**, do Lab-MEMS, COPPE/UFRJ, inaugurado em 2022. É um protótipo pioneiro que une **geração de água potável com energia solar térmica**.

O sistema produz cerca de **5 kW** — suficiente para aproximadamente **25 residências** — e mais **8 kW** recuperáveis em micro-trocadores. O dessalinizador V-AGMD produz **1.000 L/dia** de água destilada, o que pode prover água para **mais de 100 pessoas/dia**.

O foco são **comunidades remotas** do Semiárido nordestino, em articulação com o **Projeto Água Doce** — programa do governo federal que expande acesso à água potável no Semiárido nordestino por meio de dessalinização, atendendo comunidades remotas não cobertas pelo sistema tradicional de abastecimento.

6. Imagem da Instalação

(Slide apenas para mostrar a instalação física do protótipo V-AGMD na Ilha de Policogeração.)

7. Motivação e Objetivos

A motivação é a necessidade de **prever o desempenho** desse protótipo V-AGMD. Temos **dados experimentais** de aproximadamente **174 pontos** e **3 regimes de salinidade**.

Já existe um **modelo físico de 0 dimensões** disponível na literatura, publicado pelo laboratório e implementado em código C#, que serviu de referência para este trabalho.

O **objetivo geral** é avaliar estratégias de **modelagem baseada em dados** e **modelagem híbrida físico-dados** para a predição do **fluxo de permeado** e **temperaturas de saída** deste módulo de destilação.

8. Revisão Bibliográfica — Abordagens de Modelagem

Existem **três principais abordagens** de modelagem em destilação por membranas. A **abordagem física** usa princípios e leis físicas para modelar o sistema. A **abordagem data-driven** usa apenas dados experimentais para aprender a função que mapeia entradas e saídas.

E as **abordagens híbridas**, que combinam conhecimento físico com aprendizado de máquina, usando a física como regularizador para restringir o espaço de busca e melhorar a generalização com poucos dados.

Dentro dos modelos físicos, temos modelos **distribuídos** (1D, 2D) que consideram parâmetros espaciais, e modelos **reduzidos de 0 dimensões**, que é o utilizado neste trabalho. Em data-driven, temos redes neurais e outras formas de regressão. E nos híbridos, temos PINNs (Redes Neurais Integradas à Física) e modelos residuais com correção da física — a rede neural não aprende a variável diretamente, mas sim o **resíduo** em relação ao modelo físico, ou seja, o desvio entre a predição física e o valor real. A saída final é $Y_{\text{físico}} + Y_{\text{residual}}$.

9. Panorama de Publicações — Lacunas e Contribuições

Neste panorama, encontrei aproximadamente **4 publicações** usando abordagem física para V-AGMD/AGMD. A abordagem **data-driven** foi mais comum: redes neurais, regressões lineares, árvores de decisão.

Especificamente em V-AGMD com air gap, abordagens **híbridas** eu só encontrei **uma** — uma PINN. Neste trabalho, trabalhei com **todas essas arquiteturas**, incluindo **4 arquiteturas híbridas**.

Algumas **lacunas** identificadas: a primeira é a **ausência de validação cruzada** de forma geral na modelagem desses sistemas. A maioria usa partição única, que ignora a estrutura dos grupos experimentais.

A segunda lacuna é a **seleção de modelos** baseada apenas em valores absolutos de métricas de erro, como RMSE, sem considerar a **margem estatística inerente**. Isso acaba favorecendo modelos desnecessariamente complexos.

A terceira é que modelos híbridos são **praticamente inexistentes** especificamente para V-AGMD com air gap.

As **contribuições** deste trabalho são: implementação de **validação cruzada estruturada por regime de salinidade** (treino em 2 regimes, teste no terceiro); uso de **critério de seleção** que considera o erro da estimativa da métrica para favorecer modelos menos complexos; e **experimentação inédita** de 4 arquiteturas híbridas físico-dados aplicadas ao V-AGMD.

10. Sumário da Apresentação / Transição

A apresentação está dividida em **5 blocos**. Vamos agora para a **fundamentação teórica**.

11. Princípios da Destilação por Membranas

Aqui estão os princípios que regem a destilação por membranas, focando nesta arquitetura específica. Você tem **dois fluxos principais**: um fluxo de **água quente** e um fluxo de **água fria**, separados por uma **membrana** e um **air gap**.

A membrana é **hidrofóbica** — ela só permite a passagem de **vapor**. A diferença de temperatura entre os dois lados gera um **gradiente térmico**, que aumenta a pressão de vapor do lado quente, fazendo com que as moléculas de água evaporem e atravessem a membrana.

O **air gap** funciona como **isolante térmico** — o ar é um ótimo isolante, então impede a troca de calor entre os dois lados, tornando o sistema energeticamente eficiente.

O **vácuo parcial** é aplicado para compensar o impedimento ao transporte de massa causado pelo air gap, incentivando o fluxo de vapor.

Esta tecnologia **opera em temperaturas médias (60-80°C)**, é compatível com **calor residual** de processos industriais, e funciona muito bem acoplada a **projetos de cogeração**. Isso a torna ideal para integração com fontes renováveis e sistemas de aproveitamento energético.

12. Modelo Físico — Três Níveis

É importante distinguir **três níveis** de modelos físicos na literatura. Os **modelos distribuídos** (1D, CFD 2D) discretizam o módulo em dezenas de segmentos, resolvendo equações em cada ponto — capturam perfis espaciais mas têm alto custo computacional.

Os **modelos de balanços globais** aplicam balanços de massa e energia em estado estacionário sem discretizar o domínio.

E os **modelos reduzidos 0D**, como o de Lisboa (2024) usado neste trabalho, tratam o módulo como um volume único com grandezas médias. Não resolvem equações diferenciais, apenas balanços globais e relações algébricas — custo computacional baixo, mas perdem detalhes como gradientes axiais e polarização térmica.

13. Fundamentos de Aprendizado de Máquinas

O aprendizado de máquina, de forma geral, é voltado ao **aprendizado a partir dos dados**, identificando padrões e relações.

Aprendizado de máquina se divide em dois ramos principais: **regressão** e **classificação**. Em **regressão**, temos uma função real Y que queremos aproximar por uma função $f(X)$, sempre com um erro associado. O objetivo é **minimizar esse erro**.

As métricas utilizadas: a **Raiz do Erro Quadrático Médio (RMSE)** mede o somatório dos erros com penalização para erros maiores. O **Coefficiente de Determinação (R^2)** varia de 0 a 1 — mas, na biblioteca utilizada (scikit-learn), ele pode ser **negativo** quando o modelo tem **viés elevado**. O scikit-learn calcula R^2 como $1 - (S_{\text{res}} / S_{\text{tot}})$: se o modelo tem viés sistemático (como o modelo 0D para as temperaturas), S_{res} pode ser **maior que S_{tot}** , resultando em R^2 negativo.

Sobre a **divisão dos dados**: no treinamento, dividimos em **treinamento**, **validação** e **teste**. O treino ajusta os parâmetros; a validação orienta a escolha de hiperparâmetros; o teste avalia o desempenho final em dados não vistos.

Pré-processamento dos dados: o **Z-score** centraliza cada variável subtraindo a média e dividindo pelo desvio padrão, colocando todas em escala comparável. Isso evita que variáveis com magnitudes maiores dominem desproporcionalmente o ajuste do modelo. É uma etapa que transforma os dados brutos em formato adequado para o modelo, garantindo que diferenças de escala ou distribuição entre variáveis não distorçam o aprendizado.

14. Famílias de Modelos

Quatro famílias de modelos foram comparadas. Vou explicar rapidamente cada uma, começando pelos **modelos lineares**. O **OLS** é a regressão linear clássica — minimiza a soma dos quadrados dos resíduos, sem nenhuma regularização. O **Ridge** adiciona penalização L2: encolhe os coeficientes sem zerá-los, útil quando há multicolinearidade. O **Lasso** usa penalização L1: pode zerar coeficientes, funcionando como seleção automática de features. E o **ElasticNet** combina L1 e L2 — herda a seleção do Lasso e a estabilidade do Ridge simultaneamente.

Segunda família: árvores de decisão. A **Decision Tree** simples faz partições binárias recursivas nos dados. É intuitiva mas muito propensa a overfitting — se deixar crescer demais, decora os dados de treino. O **Random Forest** treina várias árvores em paralelo com bootstrap (bagging) — a média delas reduz a variância, evitando overfitting. E o **Gradient Boosting** treina árvores em sequência: cada nova árvore corrige os resíduos da combinação anterior, melhorando iterativamente.

Terceira família: redes neurais. Trabalhamos com MLPs: redes fully connected com ativação não linear entre as camadas — ReLU ou tanh — que permitem aprender relações complexas. O ajuste é por backpropagation com gradiente descendente. Os hiperparâmetros que ajustamos foram: número de camadas ocultas e neurônios, função de ativação, taxa de aprendizado, regularização L2 e early stopping para evitar overfitting por convergência.

Quarta e última família: arquiteturas híbridas, que incorporam o modelo físico 0D de quatro formas diferentes. O **PhyInput** simplesmente adiciona as predições do modelo 0D como features extras de entrada. O **PhyResidual** — que foi o grande vencedor para o Fluxo — aprende o resíduo: a saída é $Y_{\text{físico}} + \text{resíduo}$, ou seja, a rede só precisa corrigir o desvio do modelo físico. O **PhyHybrid** combina as duas abordagens. E o **PhyLoss** usa a física como regularização na função de perda, penalizando desvios das leis físicas.

15. Visão Geral dos Procedimentos

Visão geral dos procedimentos: começo com os **dados experimentais**, realizo etapas de **preparação dos dados** — padronização, análise de correlações. Depois a **análise exploratória** calcula as correlações de Pearson e Spearman para avaliar relações entre variáveis.

A modelagem segue **3 estágios** de complexidade crescente: **Stage 0** com modelos clássicos (regressões lineares e árvores de decisão), **Stage 1** com redes neurais e **Stage 2** com arquiteturas híbridas.

Finalmente, o modelo selecionado é comparado com o **modelo físico 0D**.

16. Dados Experimentais

São **174 pontos experimentais**, **3 regimes de salinidade**: 10, 40 e 70 g/L de NaCl. **5 entradas**: temperatura de alimentação, temperatura de refrigeração, vazão de refrigeração, pressão de vácuo e concentração de sais. **3 saídas**: fluxo de permeado, temperatura de saída da alimentação, temperatura de saída do refrigeração.

17. Decisões da Preparação dos Dados

Escalonamento: foi escolhido o **Z-score**. Ele preserva a distribuição original dos dados, medindo em desvios-padrão — cada ponto em número de desvios-padrão da média, sem compressão artificial causada por valores extremos.

Validação: foi usado **GroupKFold**, que separa os folds por regime operacional. Isso orienta a busca de hiperparâmetros para capacidade de extrapolação — diferente do KFold comum, que só avalia interpolação.

18. Fluxo de Validação Cruzada e Seleção Parcimoniosa

O fluxo completo adotado: **GroupKFold** separa os folds por regime operacional → **RMSE** médio com erro padrão → **regra do 1-SE** considera todos os modelos dentro de 1 erro padrão do melhor → **seleção final** pelo modelo de menor complexidade.

19. Busca de Hiperparâmetros

Para cada **variável de saída**, fiz uma **busca de hiperparâmetros personalizada**. Isso significa que para cada modelo, tenho **3 fits diferentes** — um para cada target (Alim_T_out, Ref_T_out, Fluxo).

As famílias e seus parâmetros: **Lineares** → alpha de regularização; **Árvores** → profundidade, estimadores, learning rate; **Redes Neurais** → arquitetura, LR, L2, ativação; **Híbridos** → L2 (congelados) e + L2 (PhyLoss).

20. Resultados — Modelos Lineares

Aqui os resultados dos modelos lineares. Para cada target, vemos tanto o **RMSE de validação cruzada** quanto o **RMSE de teste**.

21. Árvores de Decisão — Eliminadas

As árvores de decisão **não foram os melhores resultados** para nenhum dos parâmetros de saída. Foram eliminadas da corrida, restando a avaliação entre o melhor modelo de **regressão linear**, a **rede neural baseline** e os **híbridos**.

22. Resultados — Análise por Variável de Saída

Para **Alim_T_out**, o melhor modelo foi a **rede neural (baseline Alim)**, mas totalmente comparável com a regressão linear — o que indica uma relação aproximadamente linear.

Para **Ref_T_out**, o melhor foi o **Ridge (regressão linear)**. Novamente, performances muito comparáveis entre os modelos.

Para **Fluxo**, foi o único que teve performance melhor no modelo **híbrido (PhyResidual)** — a principal demonstração mensurável da vantagem da incorporação da física.

23. Arquiteturas Híbridas — Explicação

As arquiteturas híbridas combinam o **modelo físico 0D** com redes neurais. A rede neural **aprende correções sistemáticas** — como o viés de aproximadamente **1,58°C** que o modelo 0D tem para a temperatura de alimentação. O modelo físico representa o conhecimento da física de forma interpretável, e a rede corrige o que o modelo simplificado não consegue capturar.

Este papel de **corretor de viés** é a principal contribuição mensurável da arquitetura residual. Estudos auxiliares adicionais com novos pontos experimentais fora deste regime poderiam avaliar se a arquitetura híbrida realmente auxilia na extrapolação verdadeira.

24. Comparação Final

Comparação final: **PhyResidual** foi o melhor para **fluxo** e **temperatura de alimentação**. **PhyHybrid** venceu para **temperatura de saída do refrigeração**. A seleção foi feita pelo **critério 1-SE entre famílias**, priorizando o modelo mais simples dentro de 1 desvio padrão do melhor.

O **modelo 0D** tem R^2 negativo para **Alim_T_out**, demonstrando que há um viés sistemático que o modelo simplificado não captura, mas que as arquiteturas híbridas conseguem corrigir.

25. Conclusões

Conclusões principais: o **PhyResidual** vence para fluxo e temperatura de alimentação; o **Phy-Hybrid** vence para temperatura de saída. Para as temperaturas, tanto a rede neural quanto a

regressão linear tiveram performances muito parecidas — diferenças sutis, com uma levemente melhor para cada target.

Para o **fluxo**, o ganho do PhyResidual foi a principal demonstração da vantagem da hibridização: corrigir o viés dos modelos data-driven usando a física como referência.

Como **trabalhos futuros**: substituir o modelo **0D pelo modelo 2D** já disponível no laboratório como referência física; construir **PINNs a partir das EDOs do modelo 2D**, tanto como surrogate (apenas física, sem dados) quanto no modo que também incorpora dados experimentais na função de perda.