



Visão Geral do Pipeline



Etapa 1: Dados Experimentais

Estruturação do conjunto de dados para modelagem preditiva do sistema V-AGMD

- 174 pontos experimentais do sistema V-AGMD piloto (LabMEMS/COPPE)
- 3 regimes de salinidade: 10, 40 e 70 g/L de NaCl
- 5 entradas: $T_{in,alim}$, $T_{in,ref}$, $vazão_{ref}$, P_{vac} , C_{NaCl}
- 3 saídas: Fluxo de permeado, $T_{out,alim}$, $T_{out,ref}$



Entradas controladas (X)						Saídas (Y)		
$T_{alim,in}$ (°C)	$T_{ref,in}$ (°C)	$Vazão_{ref}$ (L h ⁻¹)	P_{vac} (mbar)	C_{NaCl} (g L ⁻¹)		$T_{alim,out}$ (°C)	$T_{ref,out}$ (°C)	Fluxo de permeado (L h ⁻¹ m ⁻²)
1	60,0	15,0	120,0	80,0	20,0	45,2	18,1	14,6
2	60,0	20,0	120,0	80,0	20,0	44,3	23,2	12,8
...	...	...	...	...	...	...	...	...
<i>i</i>	70,0	15,0	180,0	120,0	35,0	54,7	17,9	18,3
...	...	...	...	...	...	...	...	...
<i>n</i>	80,0	25,0	240,0	160,0	50,0	61,3	27,6	21,9

Exemplo de ponto experimental *i*

$X \in \mathbb{R}^{n \times 5}$
matriz de variáveis de entrada

$Y \in \mathbb{R}^{n \times 3}$
matriz de variáveis de saída



Cada linha da base representa uma condição operacional testada, com entradas controladas e respostas medidas ou calculadas.



Problema de regressão supervisionada multissaiada

Etapa 2.1: Padronização


- Padronização Z-score aplicada em **entradas e saídas** (X e Y)
- Ajustada apenas no treino de cada partição (fold)
- Evita vazamento de informação entre treino e validação
- Garante que todas as variáveis fiquem na mesma escala
- $z = \frac{x - \mu}{\sigma}$ — média 0, desvio padrão 1

Etapa 2.2: Divisão Treino/Validação/Teste

Split dos dados

- 80% treino+val → GroupKFold (3 folds)
- 20% hold-out (35 amostras) separado **antes** de qualquer modelo
- Hold-out contém amostras dos 3 regimes de salinidade
- Cada fold treina 2 regimes, valida o terceiro

Validação Cruzada GroupKFold — Particionamento por Regime



Partição dos 3 regimes em cada fold do GroupKFold. Fonte:

Elaborado pela autora.

Etapa 2.3: Seleção de *Features* e Discretização

Seleção de atributos (*Feature Selection*)

- Identificar subconjunto relevante de variáveis de entrada
- 3 categorias: filtro, wrapper, embutido ((??))
- Reduz complexidade, overfitting e redundância entre preditores

Discretização (*Binning*)

- Transforma variável contínua em intervalos discretos
- Avaliada via mistura Gaussiana (AIC/BIC)
- $2^5 = 32$ configurações testadas (contínua vs discretizada)

- **Conclusão metodológica:** a forma contínua foi mantida — discretização não trouxe ganho consistente para os 3 alvos simultaneamente
- Seleção inicial dos preditores fundamentada na descrição física do processo

Etapa 2.4: Fluxo

■ Etapas do pipeline:



Métricas de erro

- **Erro de generalização:** média do RMSE entre os 3 folds do GroupKFold
- Mede o desempenho esperado em regimes não vistos

Avaliação final

- **Erro de teste:** RMSE no hold-out (35 amostras)
- Hold-out contém amostras dos 3 regimes — avaliação em condições representativas

Etapa 3: Critérios de Seleção

Critério hierárquico:

- 1º: menor $RMSE_{CV}$ no fluxo
- 2º: modelos dentro de 1 desvio padrão do melhor
- 3º: menor complexidade entre eles

Medida de complexidade: número de parâmetros treináveis

Seleção por target:


- Flux: PhyResidual (base Alim) — RMSE 0,060
- $T_{alim,out}$: PhyResidual (base Alim) — RMSE 0,141
- $T_{ref,out}$: PhyHybrid (base Alim) — RMSE 0,211

Etapa 4: Análise Exploratória

- Objetivo: identificar padrões, tendências e relações entre variáveis antes da modelagem
- Coeficiente de correlação de Pearson: mede associação linear entre duas variáveis
- Coeficiente de correlação de Spearman: mede associação monotônica (postos)
- Comparação entre Pearson e Spearman indica se relação é aproximadamente linear
- Mapas de calor (*heatmaps*) para visualização das correlações


Pearson

Pearson Correlation: Features × Targets



Spearman

Spearman Correlation: Features × Targets







Etapa 5: Modelo Físico Reduzido 0D

Nível	Descrição	Exemplos
Distribuído	Discretiza o domínio espacial; resolve perfis de temperatura e concentração ao longo do canal	1D (difusão molecular + Knudsen), 2D/CFD
Reduzido 0D	Parâmetros concentrados; balanços globais de massa e energia; resistências equivalentes	Modelo adotado neste trabalho
Global	Balanços de massa e energia em estado estacionário; sem discretização do domínio	Cálculos de fluxo, GOR e SEC

- 3 funções: referência física, comparativo e fonte de informação para híbridos
- Código em C executado via Python — gera coluna `phy`

««««< HEAD
««««< HEAD




Validação Cruzada e Seleção de Modelos

GroupKFold por Regime

- K=3 partições: um regime reservado p/ validação
- Grupo = Regime (10, 40, 70 g/L)
- Evita vazamento entre amostras correlacionadas

Validação Cruzada GroupKFold — Particionamento por Regime



Partição dos 3 regimes em cada fold do GroupKFold. Fonte: Elaborado pela autora.

Seleção em 2 níveis

- **Nível 1 — Dentro de cada família:**
 - 1-SE + mínima complexidade para escolher hiperparâmetros
- **Nível 2 — Entre famílias:**
 - Comparação direta pelo menor $RMSE_{CV}$ (sem 1-SE)

Split Treino/Val/Teste

- 80% treino+val: submetido ao GroupKFold (3 folds)
- 20% hold-out: separado **antes** de qualquer treino
- Hold-out contém amostras dos 3 regimes

Busca de Hiperparâmetros

Hiperparâmetros ajustados por família: regularização (Ridge, Lasso, ElasticNet), profundidade (DT, RF, GB), arquitetura (MLP, Keras). Busca restrita a L2 nos híbridos.